



Coding agents e o novo workflow de engenharia de software

Dossiê de aprofundamento — análise vertical do tema da semana

Vitor Wilher¹

6 de setembro de 2026

¹Bacharel e Mestre em Economia pela UFF, Candidato ao PhD em Economia pela EPGE/FGV. É Especialista em Ciências de Dados e Inteligência Artificial Generativa pela PUC-Rio. Atualmente, exerce a função de Data Tech Lead na Análise Macro (<http://analisemacro.com.br>). Saiba mais em <https://github.com/vitorwilher>.

Índice

Coding agents e o novo workflow de engenharia de software	3
O deslocamento do foco: de escrever código para dirigir o processo	3
A anatomia do novo workflow: planejamento, execução, deploy	3
As cinco competências-chave para operar agentes	3
Contra o hype: por que “agentes autônomos por horas” é exagero	4
Spec-driven development como formalização metodológica	4
Ferramentas periféricas e ecossistema em consolidação	4
Sinais do estado da arte em performance de coding	4
Do prompt ao contexto: o novo gargalo	5
Números-chave	5
Narrativas em disputa	5
Implicações para o Boletim AM	6
Fontes (15 newsletters)	6

Coding agents e o novo workflow de engenharia de software

O deslocamento do foco: de escrever código para dirigir o processo

Andrew Ng, em sua carta semanal no The Batch, argumenta que a habilidade de usar coding agents tornou-se a competência mais rapidamente evolutiva no rol de skills centrais de engenharia de IA — evoluindo mais rápido do que qualquer outra habilidade top-level. A ferramenta agentiva não substitui o workflow tradicional de engenharia de software, mas redistribui radicalmente a alocação de esforço humano: o engenheiro deixa de gastar a maior parte do tempo escrevendo código e passa a concentrar-se em decidir o que construir, desenhar arquitetura, escrever spec e verificar outputs. O paralelo histórico é relevante — assim como compiladores permitiram que programadores subissem do assembly para linguagens de alto nível, os coding agents deslocam o gargalo produtivo do “digitar” para o “especificar e revisar” (The Batch, 04/09).

A anatomia do novo workflow: planejamento, execução, deploy

Ng consolida um workflow de três etapas observado em dezenas de entrevistas com engenheiros de IA sêniores e no próprio time do DeepLearning.AI. **Planejamento** engloba brainstorming, exploração da base de código existente e redação de spec com requisitos, design técnico e arquitetura, seguida de um plano de execução que deve ser interrogado quanto a premissas, segurança e overengineering. **Execução** consiste em construir, testar e verificar, calibrando a autonomia do agente contra a supervisão humana. **Deploy e monitoramento** incluem gatilhos CI/CD, revisões humanas pontuais e uso de agentes para vigiar logs, sinalizar incidentes e propor melhorias. Crucialmente, o autor insiste na natureza iterativa: falhas de verificação devem reconduzir o engenheiro a etapas anteriores — capacidade de julgamento que distingue o usuário maduro do usuário ingênuo (The Batch, 04/09).

As cinco competências-chave para operar agentes

O ensaio destrincha cinco skills que definem o operador maduro. **Direcionar o workflow** exige entendimento profundo dos trade-offs entre velocidade, custo, risco técnico e esforço humano — quanto investir em planejamento upfront, quando reter ownership humano sobre trechos críticos, como decompor tarefas em passos verificáveis. **Habilitar autonomia do agente** envolve calibrar o quanto se delega, quando rodar múltiplos agentes em paralelo (orquestrados por humano ou por um agente supervisor), como gerenciar contexto ao longo das fases de build e como configurar permissões para limitar risco de vazamento ou destruição de dados. **Revisar o trabalho** exige desenhar testes automatizados e comportamentais adequados, uso de eval sets com LLM-as-judge, revisão de código agentiva e auditorias de segurança — com inserção judiciosa de revisão humana onde AI review não basta. **Customizar agente e ambiente** cobre integração de skills, plugins e MCP servers, uso de hooks para automatizar partes repetíveis, manutenção de contexto persistente (AGENTS.md, CLAUDE.md), preservação de estado entre sessões e coordenação de contexto entre desenvolvedores. **Fundamentos de coding agents** — como o agente faz retrieval, gerencia janela de contexto, como subagentes interagem, como o harness envolve o LLM — é o conhecimento que impede tratar o agente como caixa-preta e permite reconhecer falha modes como overengineering, perda de rigor por falta de verificação explícita e parada precoce (The Batch, 04/09).

Contra o hype: por que “agentes autônomos por horas” é exagero

Um dos pontos mais afiados de Ng é sua crítica direta à narrativa dominante em redes sociais de que o uso “ideal” de coding agents é deixá-los rodar autonomamente por horas queimando milhões ou dezenas de milhões de tokens. Ele reconhece que às vezes esse padrão é útil, mas afirma que a utilidade prática de tarefas long-horizon — especialmente frente ao custo — foi amplificada além da realidade. O uso efetivo, segundo ele, é um processo complexo e altamente iterativo em que a capacidade de intervir com julgamento de alta qualidade produz resultados substancialmente melhores. Essa observação é operacionalmente relevante: contradiz a visão de que a métrica correta é “tempo autônomo” ou “tokens processados” e recoloca o operador humano como fator determinante de produtividade (The Batch, 04/09).

Spec-driven development como formalização metodológica

O anúncio embutido na carta — um curso conjunto entre DeepLearning.AI e JetBrains sobre Spec-Driven Development — sinaliza uma tentativa de institucionalizar o método para além do “dê melhor contexto ao agente”. A metodologia estrutura-se em três elementos: (i) constituições de projeto, que codificam regras e convenções permanentes; (ii) spec de feature para cada mudança; (iii) loop plan-implement-verify. É a formalização do que na engenharia clássica se chamaria de “requisitos + design + validação”, agora adaptado ao ciclo de trabalho com agentes (The Batch, 04/09).

Ferramentas periféricas e ecossistema em consolidação

A newsletter AiDrops registra o lançamento do OpenClaw 2.0, agente open-source adquirido pela OpenAI, cuja segunda versão foi construída pelo próprio OpenClaw com 933 contribuidores e mais de 16 mil pull requests em sete semanas — um caso paradigmático de dogfooding em que a ferramenta constrói a si mesma. As duas features experimentais mais relevantes são **Swarm** (decomposição paralela de tarefas em subagentes que reportam a um orquestrador — o exemplo dado é ler 40 contratos em paralelo em vez de sequencialmente) e **Fleet** (múltiplos agentes rodando em containers isolados, com credenciais, workspace e rede separados, para evitar contaminação entre clientes, ambientes de teste vs produção, ou pessoal vs profissional). Isso operacionaliza duas das cinco skills que Ng descreve — autonomia calibrada e customização de ambiente (AiDrops, 01/09).

Sinais do estado da arte em performance de coding

O ciclo de lançamentos americanos da semana traz benchmarks concretos de coding: Claude Fable 5.1 lidera com 66 pontos no índice de inteligência da Artificial Analysis (mais que o dobro do antecessor); Meta Spark 1.3 supera o GPT-5.6 Sol em programação segundo Alexandr Wang; Gemini 3.8 Flash marca 73,7% no DeepSWE v1.1, atrás apenas do Opus 5 e à frente de Sonnet 5 e GPT-5.6 Sol. A tese que emerge é dupla: (i) a fronteira de coding está saturando rapidamente, com múltiplos modelos convergindo em capacidade próxima; (ii) a pressão dos modelos open-weight chineses (GLM, Qwen, Kimi) forçou os labs ocidentais a competir por custo, com Fable 5.1 cortando leitura de cache em 75% e Gemini Flash operando a fração do preço da Anthropic. Isso reduz materialmente o custo marginal de rodar workflows agentivos intensivos em tokens (AiDrops, 03/09).

Do prompt ao contexto: o novo gargalo

O levantamento das Scale-ups da Endeavor com 133 fundadores traz uma observação empírica notável: “o gargalo saiu do prompt e foi para o contexto — administrar o que entra na memória do agente virou mais crítico que escrever bons comandos”. Isso ecoa exatamente o que Ng descreve como uma das cinco skills centrais (gerenciar contexto, preservar estado, acumular learnings via retrospectivas) e sugere que a fase inicial do hype de “prompt engineering” já foi superada pela fase de “context engineering” — disciplina menos glamourosa mas mais determinante de resultado (AiDrops, 03/09).

Números-chave

- Skill de coding agents evoluindo mais rápido que qualquer outra skill top-level de AI engineering (The Batch)
- Workflow em 3 etapas: planejamento, execução, deploy/monitoramento
- 5 competências centrais: dirigir workflow, autonomia do agente, revisão, customização, fundamentos
- OpenClaw 2.0: 933 contribuidores, 16 mil+ PRs, 7 semanas de desenvolvimento
- Claude Fable 5.1: 66 pontos no índice Artificial Analysis (2x o antecessor); leitura de cache -75%; custo -45% em uso de alta autonomia
- Gemini 3.8 Flash: 73,7% no DeepSWE v1.1; US\$ 0,75/US\$ 3,75 por milhão de tokens (dobra em janeiro)
- Meta Spark 1.3: -25% de consumo de tokens vs versão anterior; US\$ 1,25/US\$ 4,25 por milhão de tokens
- Scale-ups Endeavor: 51% sem métrica de negócio atrelada à IA; 37% pretendem mais que dobrar investimento; 76% reduziram contratação
- Empresas com IA no core não demitiram em massa — realocaram para problemas mais complexos
- Empresas de até \$30 mi de faturamento têm maturidade em IA 6,3; empresas com +\$300 mi têm 5,3 (contraintuitivo)

Narrativas em disputa

Tese dominante em redes sociais: o uso ideal de coding agents é delegação autônoma prolongada, com agentes rodando por horas e queimando milhões de tokens em long-horizon tasks. Métrica de sucesso: grau de autonomia e volume processado.

Contraposição de Andrew Ng: a utilidade prática de tarefas muito longas foi amplificada além da realidade frente ao custo. O uso efetivo é iterativo, com intervenção humana de alto julgamento produzindo resultados substancialmente melhores. Métrica de sucesso: qualidade da direção do workflow, não autonomia bruta.

Tese “prompt engineering”: o skill diferencial está em escrever bons comandos.

Contraposição “context engineering” (Endeavor + Ng): o gargalo migrou para gerenciar o que entra na memória do agente, preservar estado, acumular learnings. Escrever o prompt certo é condição necessária mas insuficiente.

Tese greenfield vs brownfield: workflows uniformes servem para qualquer contexto.

Contraposição de Ng: spec para protótipo greenfield pode ser um prompt rápido; projeto brownfield com muitos usuários exige spec extensivamente verificada. A calibração é o skill.

Implicações para o Boletim AM

O tema conecta-se ao Boletim AM por três vetores macro-relevantes. **Produtividade e mercado de trabalho:** o dado das Scale-ups da Endeavor de que 76% reduziram contratação, mas quem tem IA no core deslocou o time para problemas mais complexos em vez de demitir em massa, oferece evidência microeconômica sobre o padrão de adoção — mais realocação intra-firma do que substituição líquida de trabalho, ao menos nesta fase. Para análises de payroll (o ADP surpreendeu negativamente com apenas 38 mil vagas privadas em agosto nos EUA, o pior desde janeiro), vale distinguir se o enfraquecimento reflete ajuste cíclico ou efeito estrutural de automação em white-collar tech. **Capex e valuations de tech:** o ciclo agressivo de lançamentos (Fable 5.1, Spark 1.3, Gemini 3.8 Flash) validando que centenas de bilhões em capex estão gerando produto — mas simultaneamente com pressão deflacionária de custo por token, forçando corte de preços — é insumo direto para avaliar sustentabilidade de teses como Nvidia, Dell (backlog de US\$ 95 bi em servidores de IA, mas FCF caindo 47%) e a discussão recorrente sobre “bolha de IA” que o WSJ tocou. **Barreiras de adoção corporativa:** o dado de que 51% das scale-ups não têm métrica de negócio atrelada à tecnologia, combinado com a advertência de Ng contra o hype de “agentes autônomos”, sugere que a curva de adoção real (e portanto de ganho de produtividade agregada capturável no PIB) será mais gradual do que sugerem os anúncios de produto — argumento útil para moderar projeções otimistas de aceleração de produtividade nos próximos ciclos.

Fontes (15 newsletters)

- **Daily papers of 4 Sep 2026** — daily_papers_digest@notifications.huggingface.co
- **O que podemos aprender com o evento da Rádio Novelo no MASP** — nao_responder@castnews.com.br
- **Using Coding Agents, The Most Rapidly-Evolving Core AI Engineering Skill** — thebatch@deeplearning.ai
- **Daily papers of 3 Sep 2026** — daily_papers_digest@notifications.huggingface.co
- **LollapaloozIA** — ai@newsletter.thedrops.com.br
- **O divórcio do ano no vestuário BR** — money@jornal.thedrops.com.br
- **Daily papers of 2 Sep 2026** — daily_papers_digest@notifications.huggingface.co
- **YouTube quase dobra a contagem de views de podcasts** — nao_responder@castnews.com.br
- **Daily papers of 1 Sep 2026** — daily_papers_digest@notifications.huggingface.co
- **OpenClaw 2.0: o agente virou profissional** — aidrop@mail.beehiiv.com
- **Hapvida: paciência tem preço** — money@jornal.thedrops.com.br
- **Daily papers of 31 Aug 2026** — daily_papers_digest@notifications.huggingface.co
- **Ninguém pede pra “seguir” o podcast** — nao_responder@castnews.com.br
- **OpenAI abre escritório no Brasil** — newsletter@mail.datahackers.com.br
- **Veja o futuro da IA em 5 min** — aiwhisperbr@mail.beehiiv.com